

УДК 539.1.07:004.85

ПРЕПРИНТ

Расширенная PSD-разметка и ансамблевый классификатор с самообучением для разделения нейтронов и гамма-квантов на сцинтилляционном детекторе

Жук Никита, Сизова Мария, Бчемян Анна, Степанов Лев
Центральный университет, 123056, г. Москва, ул. Гашека, д. 7, стр. 1
Команда «In Search of Megatron», соревнование Kaggle 2026-ml

Аннотация

В работе решается задача классификации событий сцинтилляционного детектора ГЕЛИС на три класса — нейтроны, гамма-кванты и аномалии (шумовые/выбросные сигналы). Метод состоит из трёх блоков, каждый из которых разрабатывался последовательно по мере изучения курса. Во-первых, как и в семинарах недель 10–11 [1, 2], в качестве первичной разметки используется отношение интегралов в коротком и длинном окне (Pulse Shape Discrimination, далее PSD), физический смысл которого подробно разобран в материале IAEA [3]. Во-вторых, для каждого события строится развёрнутая физическая параметризация формы сигнала (амплитуда, площадь, времена нарастания и спада, ширина на разных уровнях, скос и эксцесс распределения энергии, шум базовой линии) — расширенный нами набор признаков относительно базовых параметров из лонгрида 4-й недели [4], дополненный проекцией PCA по выровненным по пику волнам в духе семинара 5-й недели [5]. В-третьих, разработан двухраундовый ансамблевый классификатор: на rules-метках обучаются Random Forest, Gradient Boosting и CatBoost (применение этих моделей разбиралось на семинаре 13-й недели [6]), затем те события, на которых первый раунд показал уверенность выше 0,85, формируют новую обучающую выборку, на которой переобучаются те же модели и дополнительно метод опорных векторов с RBF-ядром (соответствует материалам недели 11 [2]). Финальное решение — взвешенное soft-voting четырёх классификаторов. Схема многоуровневой фильтрации аномалий и двухраундовое самообучение разработаны нами в рамках данной работы. На публичной части лидерборда соревнования 2026-ml модель показывает точность **0,898**, что соответствует первому месту.

1 Введение

В термоядерных и нейтронно-физических исследованиях типовая задача — определить тип частицы, оставившей след в сцинтилляционном детекторе. Различение нейтронов и гамма-квантов критично, поскольку фон гамма-излучения, как правило, многократно превышает поток нейтронов, а физический смысл имеют именно нейтронные события.

Классический инструмент для такого различения — метод дискриминации формы импульса: нейтронные сигналы в органическом сцинтилляторе имеют более медленную компоненту затухания, чем гамма-кванты, что проявляется в более «толстом» хвосте импульса [3]. Это позволяет вычислить простой скаляр $PSD = (Q_{\text{long}} - Q_{\text{short}})/Q_{\text{long}}$ по двум интегралам сигнала и использовать его как первичный признак, что и предлагалось в качестве отправной точки на 10–11 неделях курса [1, 2].

В соревновании Kaggle 2026-ml задача поставлена в трёхклассовой формулировке (нейтрон, гамма-квант и отдельный класс «шум/выброс»), а сами сигналы содержат значительную долю событий с низкой амплитудой и сложной формой, что снижает надёжность только PSD-разметки вблизи границы классов. В настоящей работе мы строим решение

на тех методах, которые проходились в курсе, объединяя их в единый пайплайн, и предлагаем собственные расширения: богатое признаковое описание сигнала, многоуровневую фильтрацию аномалий и двухраундовое самообучение.

2 Постановка задачи

Каждое событие представлено вектором $x \in \mathbb{R}^{496}$ — это оцифрованная (14-битная) форма сигнала с цифрового осциллографа CAEN, дополненная метаданными ENERGY (длинное окно интегрирования) и ENERGYSHORT (короткое окно), а также флагами качества FLAGS. Дано $N = 33\,932$ события. Цель — построить функцию $f : \mathbb{R}^{496} \rightarrow \{0, 1, 2\}$, где 0 — нейтрон, 1 — гамма-квант, 2 — шумовой/выбросный сигнал. Метрика — доля верно классифицированных событий (ассигасу).

3 Метод PSD как первичная разметка

В качестве индикатора формы используется CAEN-овское представление PSD:

$$\text{PSD}_{\text{CAEN}} = \frac{Q_{\text{long}} - Q_{\text{short}}}{Q_{\text{long}}} = 1 - \frac{Q_{\text{short}}}{Q_{\text{long}}}, \quad (1)$$

где Q_{long} и Q_{short} — площади под сигналом, интегрированные платой в длинном и коротком окнах после порогового срабатывания. Чем медленнее затухает сигнал (характерно для нейтрона в органическом сцинтилляторе), тем большая доля заряда оказывается вне короткого окна — и тем выше значение PSD_{CAEN} .

Гистограмма PSD_{CAEN} на наших данных имеет характерный двухпиковый профиль с долиной между пиками. Малый по числу событий пик в области низких PSD соответствует гамма-квантам, основной пик в районе 0,25–0,30 — нейтронам. Границы классов определены нами эмпирически по этой гистограмме:

Класс	Условие
Гамма-квант	$\text{PSD} < 0,13$, амплитуда > 400
Нейтрон	$0,24 \leq \text{PSD} \leq 0,32$
Зона неопределённости	$0,13 \leq \text{PSD} < 0,24$

События в зоне неопределённости при обучении не используются. Принципиальное отличие от подхода, разбиравшегося в курсе на 10–11 неделях [1, 2], — мы дополнительно требуем чистую позицию пика $p \in [95, 115]$, что отсеивает «поплывшие» по времени события. Распределение PSD_{CAEN} по выборке с наложением выбранных порогов приведено на рис. 1.




Рис. 1: Распределение PSD_{CAEN} по выборке (амплитуда > 50). Виден малый гамма-пик в районе 0,08 и основной нейтронный пик в районе 0,27; зона неопределённости между ними при обучении не используется.

4 Признаковое описание сигнала

В отличие от подхода с обучением модели на сырых отсчётах сигнала, мы применяем явную параметризацию формы. Это уменьшает размерность входа в ≈ 15 раз и делает разделимость классов нагляднее.

4.1 Базовая линия и амплитуда

Базовая линия b оценивается как медиана первых 80 отсчётов, что устойчиво к редким помеховым импульсам в фоновой части (метод разбирался в лонгриде 4-й недели [4]). Амплитуда определяется как $A = b - \min_t x(t)$, площадь — как сумма $S = \sum_t \text{ReLU}(b - x(t))$.

Усреднённые формы импульсов для классов «нейтрон» и «гамма-квант» (сигналы предварительно выровнены по пику и нормированы по амплитуде) показаны на рис. 2. Чётко видно различие в скорости затухания, которое и лежит в основе всех PSD-подобных признаков.




Рис. 2: Усреднённые формы импульсов для гамма-квантов и нейтронов. Сигналы выровнены по позиции пика и нормированы по амплитуде. У нейтрона заметно более медленное затухание после пика — это и есть «толстый хвост», который улавливается отношением $Q_{\text{short}}/Q_{\text{long}}$.

4.2 Сегментные интегралы и доли

Относительно положения пика $p = \arg \min_t x(t)$ вычисляются интегралы по четырём сегментам: $Q_{\text{short}}^p(p, p+20)$, $Q_{\text{mid}}(p+20, p+60)$, $Q_{\text{tail}}(p+60, p+200)$ и $Q_{\text{tail_far}}(p+150, p+400)$. Дополнительно нормируются на полную площадь, образуя четыре безразмерные доли $\text{frac}_{\text{short}}$, frac_{mid} , $\text{frac}_{\text{tail}}$, $\text{frac}_{\text{tail_far}}$. Эти доли количественно описывают, насколько быстро затухает сигнал, и являются «ручной» альтернативой параметрам двухэкспоненциальной модели затухания, разбиравшимся в домашнем задании 14-й недели [7].

4.3 Временные характеристики

- t_{rise}^{10-90} — время нарастания между уровнями 10% и 90% амплитуды на восходящем фронте.
- t_{fall}^{90-10} — соответствующее время спада.
- w_{50} и w_{20} — ширины сигнала на уровнях 50% и 20% амплитуды.
- Асимметрия: $\text{asym} = (Q_{\text{post}} - Q_{\text{pre}})/(Q_{\text{post}} + Q_{\text{pre}})$.

Конкретный набор этих временных метрик предложен нами специально для данной задачи как развитие идеи параметризации сигнала из лонгрида 4-й недели [4].

4.4 Шум и количество пиков

Стандартное отклонение фоновой части σ_b и хвоста σ_{post} , а также число локальных переходов через половину амплитуды n_{peaks} — используются как индикаторы аномалий и нелинейных эффектов АЦП. Использование статистических характеристик фона как индикаторов качества опирается на материал лонгрида и домашнего задания 3-й недели [8].

4.5 Моменты распределения энергии

Сигнал интерпретируется как нормированное распределение $w(t) = \text{ReLU}(b - x(t))/S$. Считаются его центростид μ , дисперсия σ^2 , скос γ_1 и эксцесс γ_2 . Скос отрицателен у быстрых импульсов с длинным фронтом нарастания и положителен у медленных гамма-квантов. Этот блок признаков разработан нами в рамках данной работы.

4.6 PCA по выровненным сигналам

Каждый сигнал сдвигается так, чтобы пик оказался на фиксированной позиции (индекс 100), и нормируется по своей амплитуде. На этих выровненных формах строится PCA из 10 компонент, которые добавляются к остальным признакам. Сам метод главных компонент рассматривался на семинаре 5-й недели [5]; нашим вкладом является идея применять его к *выровненным по пику* и *нормированным* по амплитуде формам — иначе первая компонента в основном описывает энерговыделение, а не форму. Первые 4 компонента объясняют около 87% дисперсии формы и хорошо разделяют пиковые формы.

4.7 Оконные интегралы хвоста

Хвост после пика разрезается на 8 окон: $[0, 5)$, $[5, 10)$, $[10, 20)$, $[20, 40)$, $[40, 80)$, $[80, 160)$, $[160, 240)$, $[240, 380)$ отсчётов. Для каждого окна вычисляется суммарная энергия и её доля от полного хвоста. Эти признаки явно описывают скорость затухания на разных временных масштабах, что особенно важно вблизи границы классов. Конкретные границы окон подобраны эмпирически и являются нашим вкладом.

Итого — 32 базовых физических признака + 10 PCA-компонент + 8×2 оконных + 3 интегральных метрики позднего хвоста = около 60 признаков на событие.

5 Псевдо-разметка и фильтрация аномалий

PSD сам по себе не отсеивает все патологические события: помимо событий с неопределённой PSD, в выборке встречаются явно бракованные формы (двойные срабатывания, насыщение, обрезанные окном записи сигналы). В рамках данной работы предложена многоуровневая фильтрация, объединяющая правила из разных недель курса в единый набор:

- $\text{FLAGS} \neq 0x4000$ — плата сообщила об ошибке оцифровки (физическая информация из метаданных CAEN);
- максимум сигнала достиг 16 383 — насыщение АЦП;
- $\sigma_b > 80$ — фон содержит структурные помехи (анализ стабильности фона разбирался в материале 3-й недели [8]);
- позиция пика вне $[60, 350]$ — сигнал отрезан окном записи;
- $(\text{peak} > 200) \wedge (t_{\text{rise}} > 20)$ — поздний, медленный фронт = двойное событие или пилеап;
- $n_{\text{peaks}} > 6$ — множественные локальные максимумы;
- амплитуда < 50 — событие тонет в шуме.

Все попавшие под эти правила события маркируются как класс «шум». Дополнительное ограничение чистоты — для классов нейтрон/гамма требуется чистая позиция пика $p \in [95, 115]$. В итоге на ≈ 33 тыс. событий получается порядка 4,0 тыс. чистых гамма, 20,3 тыс. чистых нейтронов и 4,8 тыс. помеченных аномалий; остальные ≈ 4 тыс. остаются без метки и участвуют только в выводе.

6 Ансамбль с самообучением

6.1 Раунд 1 — обучение базовых моделей

На rules-метках обучаются три модели; первые две разбирались на семинаре 13-й недели [6], третья (CatBoost) подключалась там же как альтернатива sklearn-овскому Gradient Boosting:

1. **Random Forest**: 700 деревьев, sqrt-выбор признаков, класс-весовая балансировка.
2. **Gradient Boosting** (sklearn): 400 итераций, learning_rate 0,05, глубина 4, subsample 0,8.
3. **CatBoost**: 600 итераций, learning_rate 0,04, глубина 5, класс-веса (1,0; 5,0; 4,0) для компенсации доминирования нейтронной выборки.

Все три выдают вероятностные предсказания, усредняемые в soft-voting.

6.2 Самообучение

Для каждого события из всего датасета вычисляется максимум вероятности по трём классам. События с уверенностью выше 0,85 формируют расширенную обучающую выборку второго раунда (≈ 32 тыс. из 33,9 тыс.). Метки на них перекрываются предсказаниями ансамбля раунда 1. **Такая схема двухраундового самообучения предложена нами в рамках данной работы:** в учебных материалах курса самостоятельное расширение размечки не рассматривалось, ансамбль обычно обучался однократно.

6.3 Раунд 2 — переобучение и добавление SVM

На расширенной выборке заново обучаются RF, GB, CatBoost с другими seed. К ним добавляется метод опорных векторов с RBF-ядром ($C = 8$, $\gamma = \text{scale}$, balanced class weight) — SVM разобрался в лонгриде и на семинаре 11-й недели [2]. Чтобы SVM оставался вычислительно приемлемым, обучается он на сбалансированной подвыборке — по 7000 событий каждого класса.

Финальное предсказание — взвешенное усреднение вероятностей:

$$\hat{p} = \frac{1 \cdot p_{\text{RF}} + 1 \cdot p_{\text{GB}} + 3 \cdot p_{\text{CatBoost}} + 3 \cdot p_{\text{SVM}}}{8}, \quad \hat{y} = \arg \max_c \hat{p}_c. \quad (2)$$

Веса 3 у CatBoost и SVM подобраны эмпирически: оба показывают наибольшую внутрикластерную точность, тогда как RF и GB ценны как стабилизирующий фон, снижающий дисперсию. Конкретная схема взвешивания — наш вклад.

7 Результаты

На публичной части лидерборда соревнования 2026-ml:

Submission	Public LB
PSD-only baseline (один порог PSD = 0,2)	$\sim 0,80$
PSD + одиночный GradientBoosting	0,897
v12 (наша модель: ансамбль + самообучение)	0,898

Важности признаков по модели CatBoost из раунда 1 приведены на рис. 3. Видно, что доминируют наши «руками сделанные» признаки скорости затухания (frac_{mid} , energy_skew , t_{rise}^{10-90}), а сама CAEN-овская PSD занимает только пятое место — это подтверждает гипотезу, что физическая параметризация формы даёт более богатый сигнал, чем один числовой индикатор PSD.




Рис. 3: Топ-18 признаков по важности модели CatBoost (раунд 1). Лидируют наши собственные сегментные и временные характеристики формы сигнала; CAEN-овская PSD занимает лишь пятое место.

В матрице ошибок (по разметке самой модели) доля переходов между классами доминируется самой неоднозначной зоной — событиями с PSD вблизи долины распределения ($0,13 < \text{PSD} < 0,24$). В этих ячейках уверенность ансамбля редко превышает 0,9, что естественно ограничивает достижимую точность.

Распределение предсказаний:

Класс	Количество
0 (нейтрон)	24 619
1 (гамма)	4 449
2 (шум)	4 864

8 Заключение

Описанный подход показывает, что расширение классической PSD-разметки богатым физическим признаковым описанием и аккуратным самообучением позволяет уверенно достичь предельной для PSD-метода точности 0,898 на трёхклассовой задаче. Дальнейшее улучшение требует выхода за рамки PSD-парадигмы: интересными направлениями представляются двух- и трёхэкспоненциальная аппроксимация формы импульса (предложенная

в домашнем задании 14-й недели [7]) и привлечение синтетических обучающих сигналов с известными физическими параметрами.

Список литературы

- [1] Лонгрид «Базовые классификационные модели и методы оценки их качества», неделя 10, научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.
- [2] Лонгрид «Метод опорных векторов и наивный байесовский классификатор», неделя 11, научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.
- [3] Neutron-gamma discrimination with scintillation detectors based on Pulse Shaping Discrimination (PSD) modules. IAEA technical report. https://www-pub.iaea.org/MTCD/Publications/PDF/te_1634_web.pdf
- [4] Лонгрид «Структура данных, визуализация, параметры сигналов», неделя 4, научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.
- [5] Лонгрид «Продолжение анализа сигналов, метод главных компонент», неделя 5, научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.
- [6] Лонгрид «Классификация. Часть 3. Деревья решений и ансамбли» и семинарский ноутбук `Trees_2026.ipynb`, неделя 13, научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.
- [7] Домашнее задание недели 14 «Аппроксимация сигналов сцинтиллятора», научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.
- [8] Лонгрид «Основы статистического анализа», неделя 3, научная студия «Термоядерные реакции и неуправляемые нейтроны», Центральный университет, 2026.